# Notes Méthodologiques — P8 AWS · Stéphane BARRÉ · Mars 2026

## Résultat

Cluster `j-10D17Y4KI6SBM` · Step `s-00367443M91CBHEI65G8` · **COMPLETED · 20 min 44 s** · 15 mars 2026 22 688 images · 1 280 features · k=50 · 83,7% variance · 92 MB Parquet · eu-west-3 Paris ✅

---

## Ordre de configuration AWS

**1. IAM** → créer `p8-user` avec 3 politiques : S3FullAccess + EMRFullAccessPolicy_v2 + IAMFullAccess
→ `aws emr create-default-roles` pour créer EMR_DefaultRole + EMR_EC2_DefaultRole

**2. S3** → bucket `p8-fruits-bs` en eu-west-3
→ upload dataset : `aws s3 cp "...fruits-360/Test" s3://p8-fruits-bs/Test --recursive`

**3. EMR** → emr-6.15.0 · 2×m5.xlarge · Hadoop+Spark+JupyterEnterpriseGateway
→ Bootstrap : `urllib3<2.0` EN PREMIER, puis `tensorflow-cpu==2.11.0`
→ Soumettre le script via **Step EMR** (spark-submit) — pas JupyterHub

---

## Erreurs rencontrées et solutions

| Erreur | Cause | Solution |
|---|---|---|
| `AttributeError: _ARRAY_API not found` | NumPy 2.0 incompatible TF 2.11 | `pip install numpy==1.23.5 tensorflow==2.12.0` |
| `Py4JJavaError` binaryFile | winutils.exe manquant Windows | Télécharger winutils + `setx HADOOP_HOME` + redémarrer |
| `AccessDenied create-default-roles` | IAMFullAccess manquant sur p8-user | Ajouter IAMFullAccess puis relancer |
| Popup vérification carte bloquée | Chrome bloque la popup | Basculer sur Edge |
| Instances `r8g.xlarge` par défaut | EMR choisit le type le plus récent | Changer manuellement en `m5.xlarge` |

---

### Règles à retenir

- `urllib3<2.0` **EN PREMIER** dans le bootstrap (avant tensorflow)
- `tensorflow-cpu` et non `tensorflow` — pas de GPU sur m5.xlarge
- **Résilier le cluster après COMPLETED** — sinon facturation continue
- `spark-submit` via Step EMR > JupyterHub — plus simple, pas de tunnel SSH
- **eu-west-3 dès le départ** — impossible de migrer après