Procédure de configuration AWS

Projet P8 — Déployez un modèle dans le cloud

Stéphane BARRÉ · OpenClassrooms · Mars 2026

Ce document présente les étapes réalisées pour configurer AWS et exécuter le pipeline PySpark sur EMR. Chaque étape est illustrée par une capture réelle.

Résultat Final

Cluster ID :	j-10D17Y4KI6SBM
Step ID :	s-00367443M91CBHEI65G8
Statut :	● COMPLETED
Durée :	20 minutes 44 secondes
Images :	22 688 traitées · 92 MB Parquet · eu-west-3 Paris

Sommaire

1. **Configuration IAM**
   Utilisateur p8-user · Politiques · Rôles EMR
2. **Configuration S3**
   Bucket eu-west-3 · Upload 1,28 Go via AWS CLI
3. **Création du cluster EMR**
   emr-6.15.0 · 2×m5.xlarge · Bootstrap TensorFlow
4. **Exécution et résultats**
   Step COMPLETED · 20 min 44 s · 24 Parquet S3

1 — Configuration IAM (Identity & Access Management)

IAM gère les droits d'accès AWS. Sans IAM, aucun service ne peut communiquer.

1.1 Création de l'utilisateur p8-user

Console AWS → IAM → Personnes → Créer un utilisateur

- Nom : p8-user (principe du moindre privilège — pas utiliser le compte root)
- Ne pas cocher 'Fournir l'accès à la console'
- Méthode : Attacher directement des politiques

Capture 1 — Tableau de bord IAM

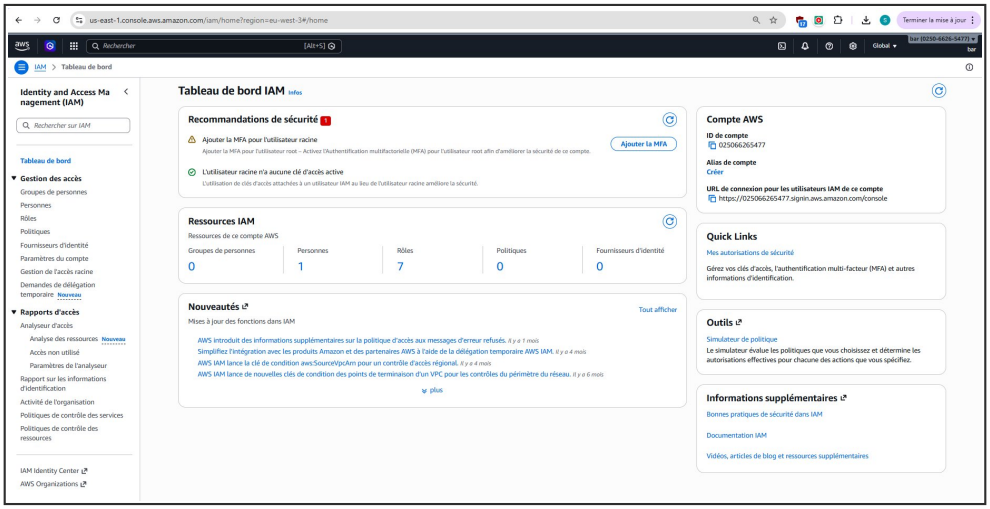

1.2 Politiques attachées à p8-user

- **AmazonS3FullAccess — accès lecture/écriture S3**
- **AmazonEMRFullAccessPolicy_v2 — créer et gérer les clusters EMR**
- **IAMFullAccess — nécessaire pour créer les rôles EMR par défaut**

Capture 2 — p8-user avec ses 4 politiques attachées

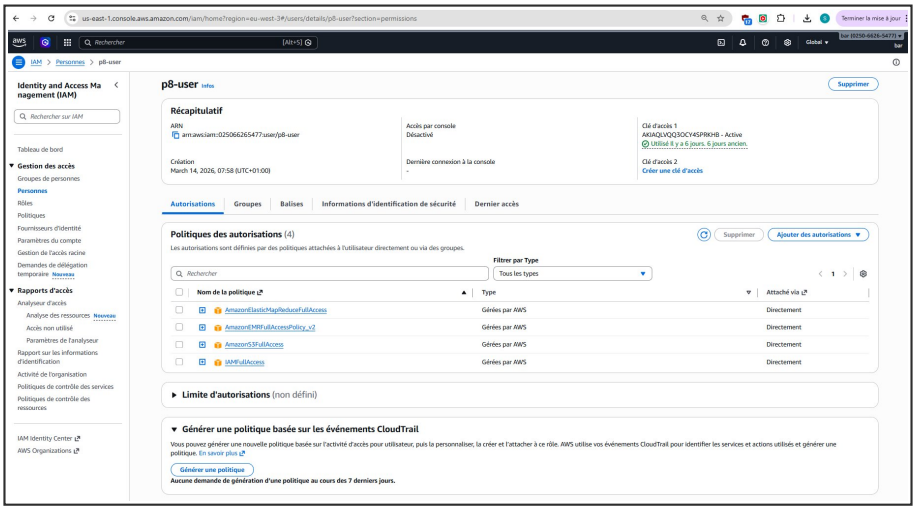

1.3 — Rôles EMR + Clés d'accès

1.3 Création des rôles IAM par défaut pour EMR

Commande AWS CLI

```
# Dans Anaconda Prompt (environnement p8)
aws emr create-default-roles
# → EMR_DefaultRole créé
# → EMR_EC2_DefaultRole créé
# → EMR_AutoScaling_DefaultRole créé
```

1.4 Création des clés d'accès CLI

⚠ Le fichier .csv des clés n'est téléchargeable QU'UNE SEULE FOIS — sauvegarder immédiatement

- Type : Interface de ligne de commande (CLI)
- Configurer via : aws configure (Access Key ID + Secret + eu-west-3 + json)

2 — Configuration S3 (Stockage)

S3 stocke les images sources et les résultats Parquet. Persiste après résiliation du cluster.

2.1 Création du bucket p8-fruits-bs

Console AWS → S3 → Créer un compartiment

- **Nom : p8-fruits-bs**
- **Région : eu-west-3 (Paris) — RGPD obligatoire**

⚠ us-east-1 (Virginie) = violation illégale RGPD pour une app française

[Image: 07_S3_compartiments_eu-west-3.png]

2.2 Upload du dataset Fruits-360 (1,28 Go via AWS CLI)

Commande upload

```
aws s3 cp 'C:\Users\...\fruits-360\Test'
        s3://p8-fruits-bs/Test --recursive
# Durée : ~15-20 minutes | 22 688 images | 131 catégories
```

- AWS CLI utilisé (plus fiable que le navigateur pour les gros fichiers)

Capture 4 — Bucket avec ses 4 dossiers (Test, scripts, logs, Results)

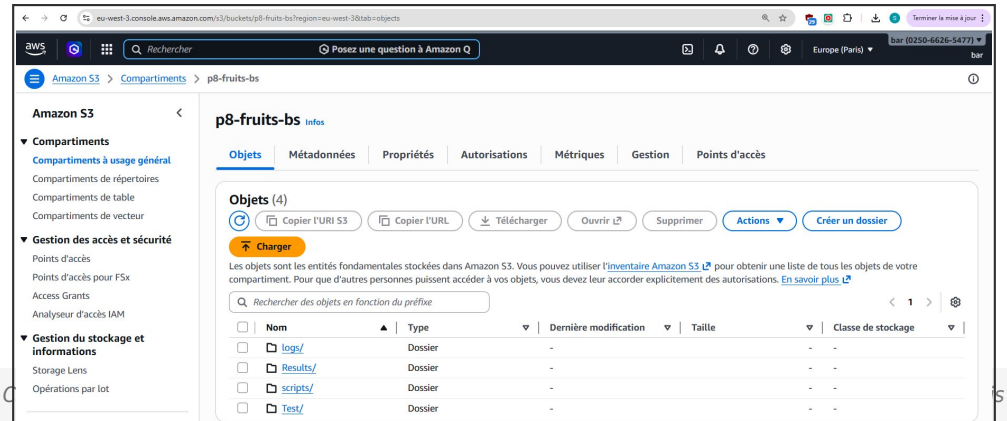

3 — Création du Cluster EMR

3.1 Configuration du cluster

Console AWS → EMR → Créer un cluster

Version EMR	emr-6.15.0
Applications	Hadoop + Spark + JupyterEnterpriseGateway
Instance Primaire	1 × m5.xlarge (4 vCPU · 16 GB RAM)
Instance Noyau	1 × m5.xlarge (4 vCPU · 16 GB RAM)
Total cluster	2 machines · 8 vCPU · 32 GB RAM
Région	eu-west-3 (Paris) — RGPD
Rôle service	EMR_DefaultRole
Profil instance EC2	EMR_EC2_DefaultRole

3.2 Bootstrap (exécuté sur chaque nœud avant Spark)

bootstrap_tf.sh

```
#!/bin/bash
sudo pip3 install 'urllib3<2.0' \   # EN PREMIER — bug OpenSSL
    tensorflow-cpu==2.11.0 \        # cpu : pas de GPU sur m5.xlarge
    pillow numpy pyarrow pandas
```

Capture 5 — Liste des clusters EMR (cluster P8-Fruits-Cluster visible)

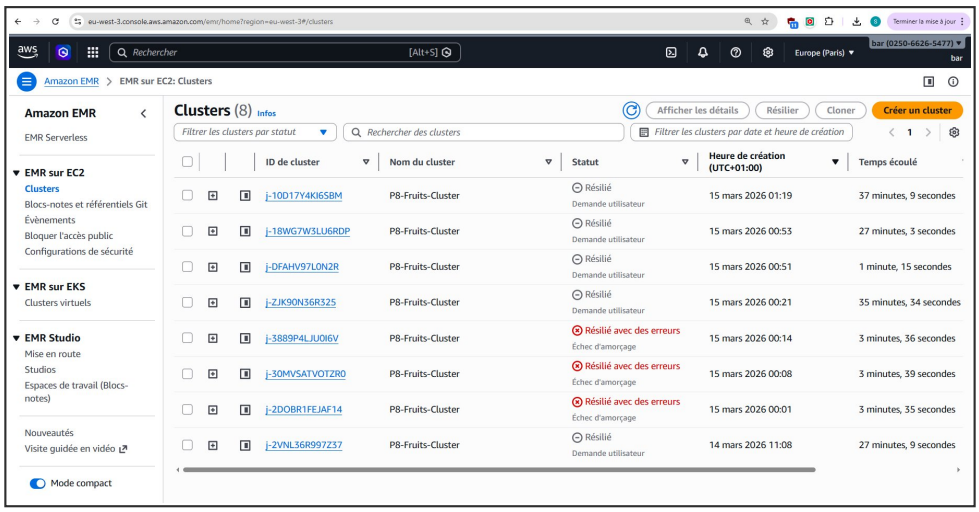

4 — Résultats — Step COMPLETED
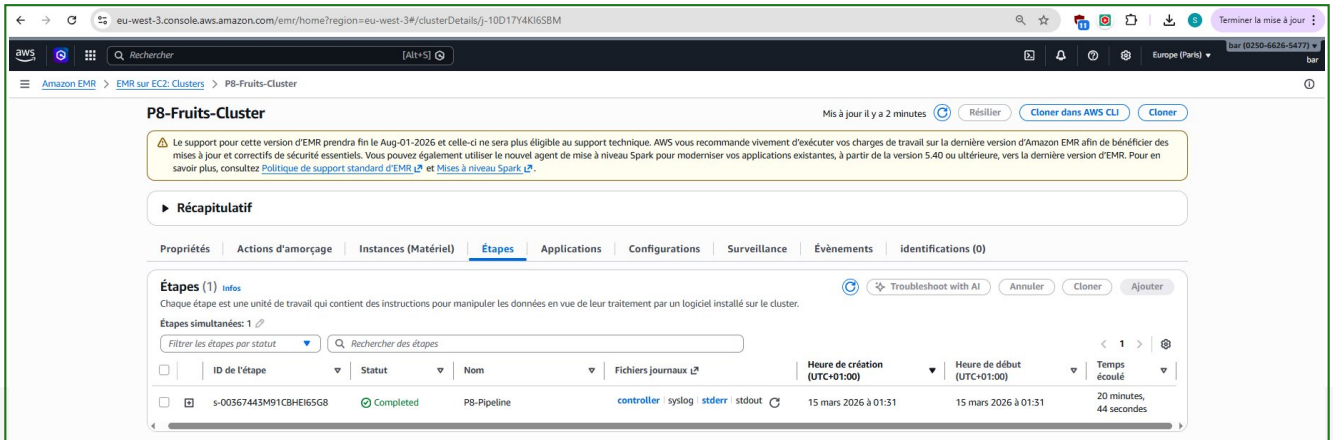
Capture 6 — Step COMPLETED · 20 minutes 44 secondes · 15 mars 2026